

# 基於深度學習技術提升 PCB 線路瑕疵檢測在 AOI 應用下的錯誤預警能力

陳旻奇、蔡沐霖、吳偉民、冷堂愷、劉晏誠、林鼎鈞

國立高雄大學電機工程學系

{a1105155|b1105129|b1115157|b1115112|a1095161|a1115162}@mail.nuk.edu.tw

## 摘要

本研究旨在基於深度學習技術，改善印刷電路板 (PCB) 中線路的瑕疵檢測問題，以及提升在自動光學檢測 (AOI) 應用中的錯誤預警能力。本次研究中使用黑白 PCB 資料集，包含六種常見瑕疵：copper、good、mousebite、open、pin-hole、short 及 spur。另外為了解決實際應用中可能發生的瑕疵資料集數量不足問題，我們團隊提出透過生成對抗網絡 (GAN) 擴充資料集，並設置多種評估指標以確保生成影像的可靠性與實用性。

模型訓練部分，本研究比較多個常見的神經網絡模型，包括 AlexNet、ConvNet、EfficientNet、GoogLeNet、MNASNet、MobileNet、ResNet、SqueezeNet、VGG、ViT 及 Xception，並調整學習率 (learning rate)、訓練輪數 (epoch)、批量大小 (batch size) 等參數，尋找最佳配置。對實驗中各模型的訓練結果進行觀察，結合過程中記錄的各種指標，進行綜觀的比較與分析，以進一步評估其在 AOI 應用中的實際效果。

**關鍵字：**深度學習、印刷電路板、自動光學檢測、瑕疵檢測、生成對抗網絡。

## 緒論

印刷電路板 (PCB) 是電子產業的關鍵元件，其品質直接影響產品性能。根據台灣電路板協會 (TPCA) 最新統計，2024 年上半年台商印刷電路板 (PCB) 全球產值達到新台幣 3722 億元，較 2023 年同期成長 6%。預計 2024 年全年產值將達 8337 億元，年增幅約 8.3%。

PCB 製造過程會遇到的問題十分繁雜，且製程中每個步驟都可能產生瑕疵，若未及時檢測，將導致產品效能下降甚至重大損失。因此，高效且精準的瑕疵檢測是重要的研究方向之一。隨著深度學習技術的快速發展，卷積神經網絡 (CNN) 已成為影像分類的主要技術。從 ResNet 到 MobileNet，再到新架構的 ViT (Vision Transformer) 提出，多種模型在結構設計與計算效率上都各具特色，且面對不同應用場景與數據特性時，表現可能存在不同的擅長區間，因此有必要對多種模型進行系統比較，以辨識其適用性與優勢。

本研究結合深度學習技術，針對 PCB 外觀瑕疵檢測的問題，訓練不同模型進行比較，再加上生成對抗網絡 (GAN) 技術的引入，可以通過數據庫增列解決資料分布不均的問題，以求進一步提高模型效能。

## 研究背景

### 資料準備

本研究使用 3000 張黑白一整塊的 PCB 影像作為資料集 [1]，每張影像均包含瑕疵 (defect) 與無瑕疵 (good) 兩種版本。根據資料集的特性，對同一塊 PCB 影像中帶有瑕疵與無瑕疵的相同區域進行裁切，提取出多個小區塊，標註為瑕疵類別或無瑕疵類別。一張 PCB 影像可以

裁切出多個小區塊，經過資料處理後，最終生成約 20000 張裁切的 PCB 區塊影像，作為訓練分類模型的資料來源。

針對數量較少的瑕疵類別，透過資料增強技術進行平衡處理，包括旋轉、翻轉、添加高斯雜訊以及模擬光源變化等操作，以使各類別的樣本數量達到均衡。

最終，模型的訓練任務為區塊分類，分類模型需辨識出 6 種類別的瑕疵 (copper、mousebite、open、pin-hole、short、spur) 以及 1 類無瑕疵的區塊 (good)，以實現高準確率的瑕疵檢測目標。黑白 PCB 資料集。




圖 1: 帶有瑕疵的黑白 PCB 影像

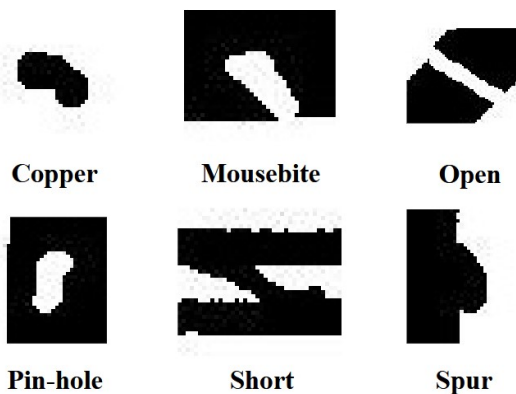


圖 2: 切割出來的 6 種 PCB 瑕疵區塊

## 研究方法

### 實驗結果

ViT

在 ViT 的模型訓練當中，觀察 accuracy、loss 曲線：

1. 隨著 learning rate 增加，模型收斂的速度也隨之增快，若 learning rate 過低 (如  $lr = 1 \times 10^{-3}$ )，會有可能遇到模型收斂困難的問題。

2. 模型訓練的準確度在 epoch10~20 的區間時就已經接近 100%，訓練集準確度接近 100%，但驗證集的準確率在收斂至約 95% 時就不再收斂。
3. 更改 batch size 參數，batch size 提升時整體 loss 皆有下降的趨勢，準確率也有相對提升，不過隨著 learning rate 提升，改變 batch size 所造成的影響也隨之變小。

在 ViT 的模型訓練當中，觀察 confusion matrix 與其指標：

1. 對於同一個 class，有時候 Precision 會低於 Recall，有時 Precision 高於 Recall，表示模型漏檢或是誤報的現象並不固定。
2. 綜觀全部的 class，表現最差 class 大多都落在 open、short、spur，而 open 的表現最差，約落在 90%。

加入 GAN 之後的變化：

1. 對於整個訓練來說，隨著 epoch 增加的模型收斂速度有略為提升。
2. 在較低 learning rate 當中的表現有得到不錯的提升，到了  $lr=1 \times 10^{-5}$  原本就很高的準確率也上升了 1~2%。

## ResNet

在 ResNet 的模型訓練當中，觀察 accuracy、loss 曲線：

1. ResNet 在訓練中不論是有無使用 GAN 擴充的資料集，几乎都是呈現無法收斂的情況<sup>4</sup>，除了設定 batch size 為 32，learning rate 為  $1e-4$  或  $2e-5$  的情況有收斂完成<sup>5</sup>。
2. 在準確度上也對應了 loss 曲線的情況，因未成功收斂而導致準確度較差，在特定數據下才有準確率達到 0.97 的情況<sup>6</sup>。
3. 針對有使用 GAN 的資料集，在 loss 曲線有收斂完成的情況下，準確率較無使用 GAN 的資料集略低 0.01 左右。

在 ResNet 的模型訓練當中，觀察 confusion matrix 與其指標：

1. 對於同一個 class，在 loss 曲線有收斂完成的情況下，precision 與 recall 都達到 0.96 左右，而未完成收斂的情況則是 precision 明顯高於 recall。
2. 綜觀全部的 class，最差的表现通常落在 open、good，而以 open 的情況又較差??。

## SqueezeNet

在 SqueezeNet 的模型訓練當中，觀察 accuracy、loss 曲線：

1. SqueezeNet 在不論是有無使用 GAN 進行擴充的資料集下，loss 曲線幾乎都有收斂，除了在 batch size 為 8 與 learning rate 為  $1e-3$ ，以本次實驗來說 batch size 極小 learning rate 極大的情況下，loss 曲線完全沒有收斂，甚至是模型完全沒有學習到特徵。
2. 而在 learning rate 為  $1e-3$  的情況下，多數的 loss 曲線會在 epoch 為 10 左右出現較大的起伏，進而影響到後面的模型收斂與最後的準確率。
3. 準確度上因為多數情況下 loss 曲線都有收斂，所以準確度普遍落在 0.96 左右，在 learning rate 為  $1e-3$ ，並且最後有收斂的情況下，準確率在 0.69 左右。
4. 針對有使用 GAN 的資料集，在 loss 曲線有收斂完成的情況下，準確率與無使用 GAN 的資料集無明顯差異。

在 SqueezeNet 的模型訓練當中，觀察 confusion matrix 與其指標：

1. 對於同一個 class，在 loss 曲線有收斂完成的情況下，precision 與 recall 都達到 0.96 左右，而未完成收斂的情況則是 precision 與 recall 數據持平，表示模型並沒有完整學習到特徵。
2. 綜觀全部的 class，最差的表现通常落在 open、good，又以 open 的情況又較差。

## 結論

## 參考文獻

[1] Papers with Code, “Deeppcb dataset,” 2024, accessed: 2025-01-24.

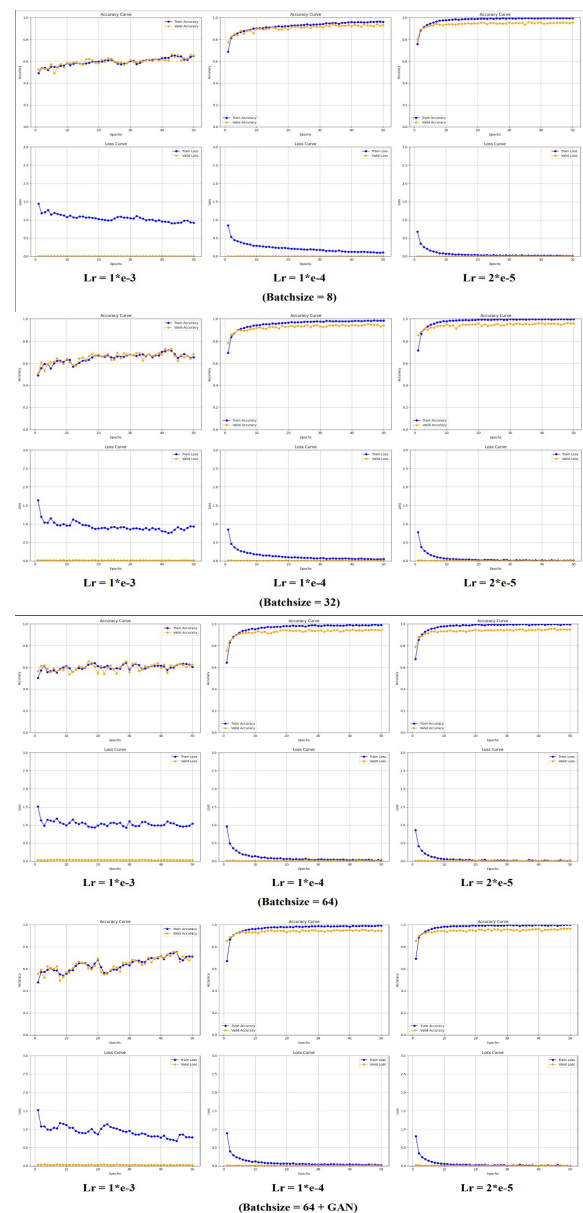


圖 3: ViT 訓練結果




圖 4: ResNet 未收斂 loss 曲線




圖 5: ResNet 已收斂 loss 曲線




圖 6: ResNet Accuracy 曲線




圖 7: ResNet Confusion Matrix