

基於深度學習技術提升 PCB 線路瑕疵檢測在 AOI 應用下的錯誤預警能力

陳旻奇、蔡沐霖、吳偉民、冷堂愷、劉晏誠、林鼎鈞

國立高雄大學電機工程學系

{a1105155|b1105129|b1115157|b1115112|a1095161|a1115162}@mail.nuk.edu.tw

摘要

本研究旨在基於深度學習技術，改善印刷電路板 (PCB) 中線路的瑕疵檢測問題，以及提升在自動光學檢測 (AOI) 應用中的錯誤預警能力。本次研究中使用黑白 PCB 資料集，包含六種常見瑕疵：copper、good、mousebite、open、pin-hole、short 及 spur。另外為了解決實際應用中可能發生的瑕疵資料集數量不足問題，我們團隊提出透過生成對抗網絡 (GAN) 擴充資料集，並設置多種評估指標以確保生成影像的可靠性與實用性。

模型訓練部分，本研究比較多個常見的神經網絡模型，包括 AlexNet、ConvNet、EfficientNet、GoogLeNet、MNASNet、MobileNet、ResNet、SqueezeNet、VGG、ViT 及 Xception，並調整學習率 (learning rate)、訓練輪數 (epoch)、批量大小 (batch size) 等參數，尋找最佳配置。對實驗中各模型的訓練結果進行觀察，結合過程中記錄的各種指標，進行綜觀的比較與分析，以進一步評估其在 AOI 應用中的實際效果。

關鍵字：深度學習、印刷電路板、自動光學檢測、瑕疵檢測、生成對抗網絡。

緒論

印刷電路板 (PCB) 是電子產業的關鍵元件，其品質直接影響產品性能。根據台灣電路板協會 (TPCA) 最新統計，2024 年上半年台商印刷電路板 (PCB) 全球產值達到新台幣 3722 億元，較 2023 年同期成長 6%。預計 2024 年全年產值將達 8337 億元，年增幅約 8.3%。

PCB 製造過程會遇到的問題十分繁雜，且製程中每個步驟都可能產生瑕疵，若未及時檢測，將導致產品效能下降甚至重大損失。因此，高效且精準的瑕疵檢測是重要的研究方向之一。隨著深度學習技術的快速發展，卷積神經網絡 (CNN) 已成為影像分類的主要技術。從 ResNet 到 MobileNet，再到新架構的 ViT (Vision Transformer) 提出，多種模型在結構設計與計算效率上都各具特色，且面對不同應用場景與數據特性時，表現可能存在不同的擅長區間，因此有必要對多種模型進行系統比較，以辨識其適用性與優勢。

本研究結合深度學習技術，針對 PCB 外觀瑕疵檢測的問題，訓練不同模型進行比較，再加上生成對抗網絡 (GAN) 技術的引入，可以通過數據庫增列解決資料分布不均的問題，以求進一步提高模型效能。

研究背景

資料準備

本研究使用 3000 張黑白一整塊的 PCB 影像作為資料集 [1]，每張影像均包含瑕疵 (defect) 與無瑕疵 (good) 兩種版本。根據資料集的特性，對同一塊 PCB 影像中帶有瑕疵與無瑕疵的相同區域進行裁切，提取出多個小區塊，標註為瑕疵類別或無瑕疵類別。一張 PCB 影像可以

裁切出多個小區塊，經過資料處理後，最終生成約 20000 張裁切的 PCB 區塊影像，作為訓練分類模型的資料來源。

針對數量較少的瑕疵類別，透過資料增強技術進行平衡處理，包括旋轉、翻轉、添加高斯雜訊以及模擬光源變化等操作，以使各類別的樣本數量達到均衡。

最終，模型的訓練任務為區塊分類，分類模型需辨識出 6 種類別的瑕疵 (copper、mousebite、open、pin-hole、short、spur) 以及 1 類無瑕疵的區塊 (good)，以實現高準確率的瑕疵檢測目標。黑白 PCB 資料集。




圖 1: 帶有瑕疵的黑白 PCB 影像

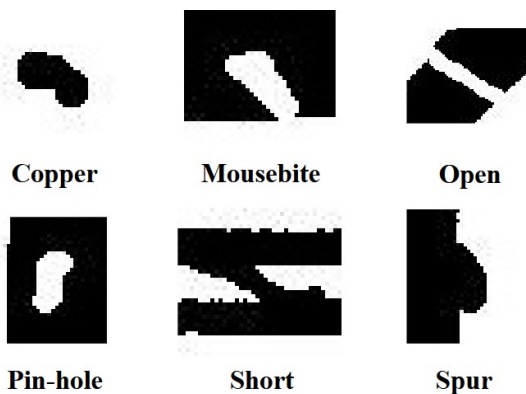


圖 2: 切割出來的 6 種 PCB 瑕疵區塊

研究方法

實驗結果

ViT

在 ViT 的模型訓練當中，觀察 accuracy、loss 曲線：

1. 隨著 learning rate 增加，模型收斂的速度也隨之增快，若 learning rate 過低 (如 $lr = 1 \times 10^{-3}$)，會有可能遇到模型收斂困難的問題。

2. 模型訓練的準確度在 epoch10~20 的區間時就已經接近 100%，訓練集準確度接近 100%，但驗證集的準確率在收斂至約 95% 時就不再收斂。
3. 更改 batch size 參數，batch size 提升時整體 loss 皆有下降的趨勢，準確率也有相對提升，不過隨著 learning rate 提升，改變 batch size 所造成的影響也隨之變小。

在 ViT 的模型訓練當中，觀察 confusion matrix 與其指標：

1. 對於同一個 class，有時候 Precision 會低於 Recall，有時 Precision 高於 Recall，表示模型漏檢或是誤報的現象並不固定。
2. 綜觀全部的 class，表現最差 class 大多都落在 open、short、spur，而 open 的表現最差，約落在 90%。

加入 GAN 之後的變化：

1. 對於整個訓練來說，隨著 epoch 增加的模型收斂速度有略為提升。
2. 在較低 learning rate 當中的表現有得到不錯的提升，到了 $lr=1 \times 10^{-5}$ 原本就很高的準確率也上升了 1~2%。

ResNet

在 ResNet 的模型訓練當中，觀察 accuracy、loss 曲線：

1. ResNet 在訓練中不論是有無使用 GAN 擴充的資料集，几乎都是呈現無法收斂的情況⁴，除了設定 batch size 為 32，learning rate 為 1×10^{-4} 或 2×10^{-5} 的情況有收斂完成⁵。
2. 在準確度上也對應了 loss 曲線的情況，因未成功收斂而導致準確度較差，在特定數據下才有準確率達到 0.97 的情況⁶。
3. 針對有使用 GAN 的資料集，在 loss 曲線有收斂完成的情況下，準確率較無使用 GAN 的資料集略低 0.01 左右。

在 ResNet 的模型訓練當中，觀察 confusion matrix 與其指標：

1. 對於同一個 class，在 loss 曲線有收斂完成的情況下，precision 與 recall 都達到 0.96 左右，而未完成收斂的情況則是 precision 明顯高於 recall。
2. 以 confusion matrix 綜觀全部的 classes，最差的表現通常落在 open、good，而以 open 的情況又較差⁷。

SqueezeNet

在 SqueezeNet 的模型訓練當中，觀察 accuracy、loss 曲線：

1. SqueezeNet 在不論是有無使用 GAN 進行擴充的資料集下，loss 曲線幾乎都有收斂⁸，除了在 batch size 為 8 與 learning rate 為 1×10^{-3} ，以本次實驗來說 batch size 極小 learning rate 極大的情況下，loss 曲線完全沒有收斂⁹，甚至是模型完全沒有學習到特徵。
2. 而在 learning rate 為 1×10^{-3} 的情況下，多數的 loss 曲線會在 epoch 為 10 左右出現較大的起伏¹⁰，進而影響到後面的模型收斂與最後的準確率。
3. 準確度上因為多數情況下 loss 曲線都有收斂，所以準確度普遍落在 0.96 左右¹¹，在 learning rate 為 1×10^{-3} ，並且最後有收斂的情況下，準確率在 0.69 左右¹²。
4. 針對有使用 GAN 的資料集，在 loss 曲線有收斂完成的情況下，準確率與無使用 GAN 的資料集無明顯差異。

在 SqueezeNet 的模型訓練當中，觀察 confusion matrix 與其指標：

1. 對於同一個 class，在 loss 曲線有收斂完成的情況下，precision 與 recall 都達到 0.96 左右，而未完成收斂的情況則是 precision 與 recall 數據持平，表示模型並沒有完整學習到特徵。
2. 以 confusion matrix 綜觀全部的 classes，最差的表現通常落在 open、good，又以 open 的情況又較差¹³。

結論

透過實驗數據的綜合分析，得到以下結論：資料擴增的影響：引入 GAN 生成的瑕疵資料後，資料多樣性有明顯提升，尤其在初期訓練階段，有助於模型 Loss 的穩定收斂。我們也觀察到 GAN 擴增資料對於不同模型成效也不一，其中 MobileNetV1 和 GoogLeNet 適應性最佳，mAP 分別提升約 1% 至 2%。

模型參數對表現的影響：

較小的 Batch size 有助於穩定訓練，但可能限制模型對細微瑕疵的 recall 表現。大批次大小則提升 recall 能力，但可能導致收斂速度變慢。Learning rate 對模型穩定性影響十分顯著，尤其是 VGG 模型，在使用極低 Learning rate（如 2×10^{-5} ）時，表現精度達到最佳，而過高的 Learning rate 則可能導致震盪以致無法收斂。

特殊情況的觀察：MNASNet 表現出較明顯的不穩定性，其 valid loss 波動顯著，且即使引入 GAN 資料，精度提升幅度有限。

整體模型表現：本實驗大中多數的模型表現較為穩定，且能適應 GAN 擴增資料的模型。而 VGG 模型則可能比較適用於極高精度的任務場景，MNASNet 則需進一步調整以提升穩定性。

未來，本研究可在以下方向展開更深入的探索：

1. 提升 GAN 資料的生成方法，提升其與實際資料特性的匹配程度，進一步增強模型對瑕疵的辨識能力。
2. 受限於訓練時長，本次模型訓練的參數選擇並不能做到全面涵蓋，可能需要探索更高效的訓練策略，以加速 Loss 收斂與提升模型精度的目的。
3. 再引入更多新的深度學習模型或技術，驗證這些模型在 PCD 瑕疵檢測領域的適用性。

參考文獻

- [1] Papers with Code, “Deeppcb dataset,” 2024, accessed: 2025-01-24. [Online]. Available: <https://paperswithcode.com/dataset/deep-pcb>

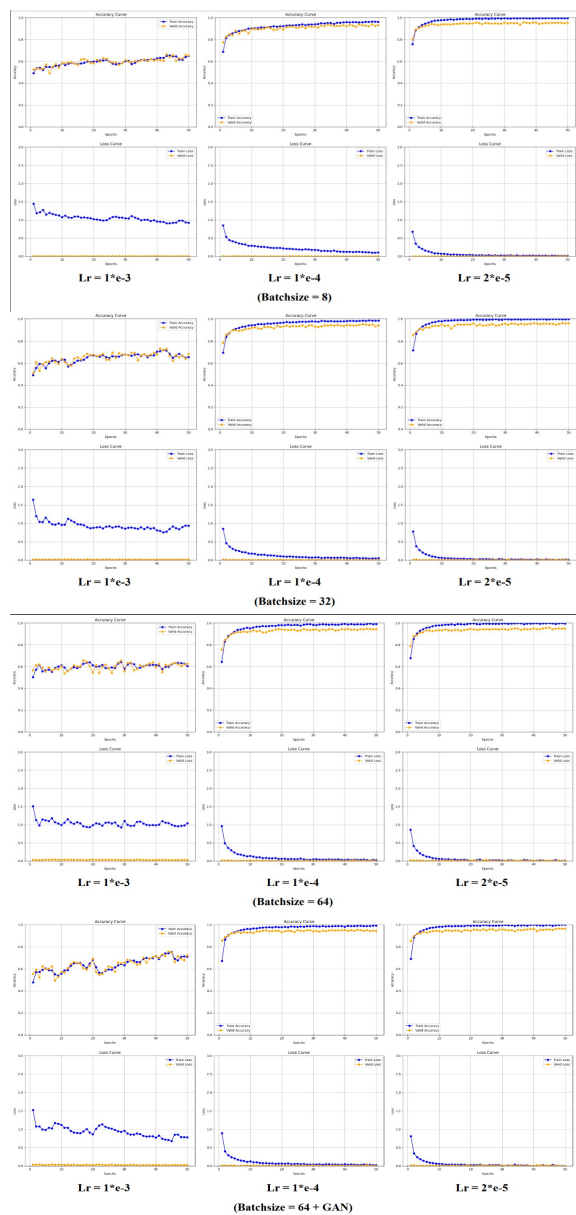


圖 3: ViT 訓練結果




圖 4: ResNet 未收斂 loss 曲線




圖 5: ResNet 已收斂 loss 曲線




圖 6: ResNet Accuracy 曲線




圖 7: ResNet Confusion Matrix




圖 10: SqueezeNet 之 loss 曲線收斂但較不穩




圖 8: SqueezeNet 已收斂 loss 曲線




圖 11: ResNet Accuracy 曲線




圖 9: SqueezeNet 之 loss 曲線表示模型無學習到特徵




圖 12: ResNet Accuracy 曲線




圖 13: ResNet Confusion Matrix